

Analítica de Datos y Herramientas de Inteligencia Artificial

Actividad 4 (Análisis Predictivo de clasificación)

Ian Kaled Sandoval Gines | A01738687
Andre Guillermo Carvajal Flores | A01738830
Johan Andre Heredia Zazueta | A01738019
Sebastian Olivares Puente | A01737568
Juan Pablo Solís Croda | A01738139

1 Objetivo del análisis

El objetivo fue clasificar oportunidades comerciales cerradas como ganadas o perdidas mediante Regresión Logística. El análisis responde a la solicitud de evaluar quince variables dicotómicas y reportar la matriz de confusión, precisión, exactitud y sensibilidad de cada análisis.

2 Bases utilizadas y variable objetivo

La variable de resultado se obtuvo de la hoja Ventas_Negadas_CRM y las variables predictoras de Negocios_CRM. Las dos bases se relacionaron mediante id_negocio.

Elemento	Definición aplicada
Variable objetivo	resultado_perdido
Clase 1	Cierre Perdido o Perdido
Clase 0	Cierre Ganado o Ganado
Registros excluidos	Etapas sin resultado definitivo, como Lead, Cotización o Negociación
Unidad de análisis	Una oportunidad de negocio identificada por id_negocio

3 Preprocesamiento de datos

El preprocesamiento se realizó antes de entrenar los modelos. Se revisaron nulos, categorías no esperadas y transformaciones necesarias para convertir las variables en indicadores binarios.

Aspecto	Tratamiento
Nulos	Se identificaron por variable. En tipo de negocio, ruta y pipeline se excluyeron registros con datos faltantes o fuera de catálogo.
Zona y estado	Los faltantes se conservaron como la categoría SIN_DATO para evitar eliminar observaciones geográficas.
Outliers categóricos	Se trataron como categorías fuera del catálogo permitido. No se aplicó IQR, porque las variables originales son categóricas.
Variables binarias	Después de la transformación, cada variable toma 0 o 1. Por ello no hay outliers numéricos en las variables finales.
Reproducibilidad	La división de datos usa semilla 42 y separación estratificada.

4 Variables dicotómicas construidas

El valor 1 indica pertenencia a la categoría descrita; el valor 0 indica cualquier otra categoría válida. Las zonas y estados seleccionados son los más frecuentes en la base después de la limpieza.

No.	Variable	Categoría representada por 1
1	cliente_nuevo	Cliente nuevo
2	ruta_si	Oportunidad de ruta: Sí
3	pipeline_ventas_main	Pipeline Ventas - Main
4	pipeline_mapeo_ruta	Pipeline Mapeo en Ruta
5	pipeline_educacion_continua	Pipeline Educación Continua
6	zona_top_1	Zona Metropolitana
7	zona_top_2	Zona Sur Este Golfo de México
8	zona_top_3	Zona sin dato
9	zona_top_4	Zona Bajío
10	zona_top_5	Zona Occidente Pacífico
11	estado_top_1	Ciudad de México
12	estado_top_2	Estado de México
13	estado_top_3	Puebla
14	estado_top_4	Tamaulipas
15	estado_top_5	Nuevo León

5 Estrategia de modelado

Se utilizó Regresión Logística porque la variable objetivo tiene dos clases: ganado y perdido. Para cada una de las quince variables se ajustó un modelo individual, usando la misma partición de datos: 80% para entrenamiento y 20% para prueba.

- Se aplicó class_weight igual a balanced para reponderar la clase minoritaria de pérdidas.
- La reponderación no crea registros sintéticos; aumenta el peso de las pérdidas durante el entrenamiento.
- Las métricas se calcularon en el conjunto de prueba, no con los mismos datos usados para entrenar.
- No se utilizaron como predictoras nombre_etapa, estatus, motivo_cierre_perdido, fecha_cierre, ultima_modificacion ni valor_negocio, porque pueden revelar el resultado final.

6 Métricas de evaluación

Exactitud es la proporción total de clasificaciones correctas. Precisión es la proporción de predicciones de pérdida que realmente fueron pérdidas. Sensibilidad es la proporción de pérdidas reales que el modelo logró detectar.

7 Resultados de clasificación

La siguiente tabla resume las métricas obtenidas para los quince modelos individuales. Las variables están ordenadas por sensibilidad, de mayor a menor.

Variable	Exactitud	Precisión	Sensibilidad
Oportunidad de ruta: Sí	0.159	0.154	0.986
Estado de México	0.289	0.176	0.972
Ciudad de México	0.339	0.183	0.944
Zona Metropolitana	0.424	0.200	0.908
Zona sin dato	0.326	0.159	0.782
Cliente nuevo	0.771	0.317	0.415
Zona Sur Este Golfo de México	0.707	0.207	0.317
Zona Occidente Pacífico	0.828	0.386	0.190
Puebla	0.764	0.202	0.176
Zona Bajío	0.766	0.183	0.148
Pipeline Ventas - Main	0.796	0.222	0.127
Nuevo León	0.839	0.417	0.106
Tamaulipas	0.816	0.171	0.049
Pipeline Mapeo en Ruta	0.843	0.400	0.028
Pipeline Educación Continua	0.846	1.000	0.007

8 Componentes de las matrices de confusión

VP son pérdidas detectadas correctamente; FN son pérdidas clasificadas como ganadas; FP son oportunidades ganadas clasificadas erróneamente como pérdidas; VN son oportunidades ganadas clasificadas correctamente.

Variable	VP	FN	FP	VN
Oportunidad de ruta: Sí	140	2	769	6
Estado de México	138	4	648	127
Ciudad de México	134	8	598	177
Zona Metropolitana	129	13	515	260
Zona sin dato	111	31	587	188
Cliente nuevo	59	83	127	648
Zona Sur Este Golfo de México	45	97	172	603
Zona Occidente Pacífico	27	115	43	732
Puebla	25	117	99	676
Zona Bajío	21	121	94	681
Pipeline Ventas - Main	18	124	63	712
Nuevo León	15	127	21	754
Tamaulipas	7	135	34	741
Pipeline Mapeo en Ruta	4	138	6	769
Pipeline Educación Continua	1	141	0	775

9 Interpretación de los resultados

Oportunidad de ruta

Ruta Sí obtuvo sensibilidad de 0.986: detectó 140 de 142 pérdidas reales. Sin embargo, tuvo precisión de 0.154 y 769 falsos positivos. Esto significa que el modelo tiende a señalar un gran número de oportunidades como pérdidas. Por ello, esta variable puede apoyar la detección temprana, pero no debe usarse sola para tomar decisiones comerciales.

Cliente nuevo

Cliente nuevo presentó un equilibrio más favorable: exactitud de 0.771, precisión de 0.317 y sensibilidad de 0.415. Detectó 59 pérdidas reales, con 127 falsos positivos. Entre las variables individuales, es una de las opciones más útiles para integrarse a un modelo combinado.

Zonas y estados

Las zonas y estados permiten segmentar el comportamiento de las oportunidades. Algunas variables geográficas mostraron sensibilidad alta, pero a costa de precisión baja. Otras tuvieron exactitud alta debido a que clasificaron correctamente muchos negocios ganados, aunque detectaron pocas pérdidas. Por ello, la exactitud no debe interpretarse de manera aislada.

Pipelines

Los pipelines Mapeo en Ruta y Educación Continua mostraron pocos verdaderos positivos. En especial, Educación Continua presentó precisión de 1.000, pero solo detectó un caso perdido. Un resultado basado en un caso es inestable y no debe considerarse evidencia suficiente de buen desempeño.

10 Efecto de cada variable sobre la pérdida

Las métricas de clasificación indican qué tan bien predice cada variable, pero no muestran por sí solas si una categoría aumenta o disminuye la probabilidad de pérdida. Para complementar este análisis, el notebook incluye una sección para calcular la tasa real de pérdida con valor 0 y 1, el coeficiente logístico, el odds ratio, su intervalo de confianza al 95% y el valor p.

Un odds ratio mayor que 1 indica asociación con mayores probabilidades relativas de pérdida; un valor menor que 1 indica asociación con menores probabilidades relativas. Este análisis describe asociación estadística, no causalidad.

11 Conclusiones y recomendaciones

- Las quince variables fueron transformadas y evaluadas de forma individual con regresión logística reponderada.
- La sensibilidad elevada debe revisarse junto con la precisión y los falsos positivos.
- Cliente nuevo, algunas zonas y algunos estados son candidatos para un modelo multivariable posterior.
- Las variables poco frecuentes deben interpretarse con cautela, aunque su precisión aparente sea alta.
- Como siguiente paso, se recomienda estimar los odds ratios y ajustar un modelo combinado con las variables que muestren asociación estadística y sentido comercial.

Conclusion principal

Las variables individuales muestran capacidades predictivas distintas. Oportunidad de ruta presentó sensibilidad alta, pero precisión baja y un número muy elevado de falsos positivos. Cliente nuevo mostró un comportamiento más equilibrado entre exactitud, precisión y sensibilidad. Ninguna variable por sí sola permite identificar pérdidas con precisión suficiente, por lo que la recomendación es combinar las variables más útiles en un modelo multivariable.